



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده مهندسی برق

گرایش مخابرات سیستم

عنوان:

بهره‌وری انرژی با کمک یادگیری عمیق در شبکه‌های مدرن

نگارش

علیرضا خیاطیان

استاد

دکتر عباس محمدی

خرداد ۱۴۰۰

صفحه	فهرست مطالب
۱.....	فصل اول مقدمه مقدمه.....
۲.....	۱-۱) شبکه های بیسیم مبتنی بر هوش مصنوعی.....
۵.....	فصل دوم ادغام در شبکه های بی سیم: محیط های رادیویی هوشمند.....
۷.....	۱-۲) نقش یادگیری عمیق در محیط های رادیویی هوشمند.....
۸.....	۲-۲) استقرار شبکه های عصبی در شبکه های بی سیم.....
۱۰.....	فصل سوم بهینه سازی بهره‌وری انرژی با یادگیری عمیق.....
۱۲.....	۱-۳) به حداکثر رساندن بازده انرژی جمع وزنی.....
۱۹.....	۲-۳) بهره‌وری انرژی در شبکه های بی سیم غیر پواسون: رویکرد یادگیری انتقال عمیق.....
۲۵.....	فصل چهارم نتیجه گیری.....
۲۶.....	منابع و مراجع.....

شکل ۱-۱ شبکه های فعلی در مقابل یک محیط رادیویی هوشمند (یا بی سیم هوشمند).....	۶
شکل ۲-۱ تلفات آموزشی و اعتبارسنجی در مقابل عدد دوره آموزشی. مشاهده می شود که پس از مرحله آموزش، شبکه ANN دچار overfitting و underfitting نشده است.....	۱۷
شکل ۳-۲ عملکرد WSEE روش مبتنی بر ANN پیشنهادی در مقایسه با بهینه جهانی و چندین الگوریتم پیشرفته.....	۱۸
شکل ۳-۴ مقایسه بین بهینه سازی مبتنی بر مدل، مبتنی بر داده، و بهینه سازی مبتنی بر انتقال عمیق - استقرار بهینه.....	۲۴
شکل ۵-۳ یادگیری و اعتبارسنجی MSE نسبی در مقابل دوره های آموزشی برای $x = 300. 600. 1500. 2100. 3000$ نمونه. برای هر مورد، عملکرد با و بدون نمونه های مبتنی بر PPP گزارش شده است. مشاهده می شود که چگونه استفاده از داده های مبتنی بر PPP به طور قابل توجهی عملکرد را بهبود می بخشد.....	۲۴

فصل اول

مقدمه

مقدمه

انتظار می‌رود شبکه‌های بی‌سیم آینده به تعداد فزاینده‌ای از دستگاه‌های متصل سرویس دهند، که نگرانی‌هایی را برای رشد سبز و پایدار ایجاد می‌کند. شبکه‌های 5G که در سال ۲۰۲۰ راه‌اندازی آن‌ها شروع شده است، باید در مقایسه با نسل قبلی بی‌سیم، بازده انرژی بالاتر از 2000 bit/J را ارائه دهند. تخمین زده می‌شود که نرخ رشد سالانه دستگاه‌های متصل، سالانه ۵۵ درصد افزایش می‌یابد و به ۶۰۷ اگزابایت در سال ۲۰۲۵ و ۵۰۱۶ اگزابایت در سال ۲۰۳۰ می‌رسد. علاوه بر حجم عظیم ترافیک برای پشتیبانی، یکی دیگر از چالش‌های مهمی که شبکه‌های بی‌سیم آینده با آن مواجه خواهند شد، ناهمگونی شدید، با بسیاری از خدمات عمودی نوآورانه‌ای است که باید ارائه شوند، که هر کدام نیازمندی‌های خاص خود را دارند:

- تأخیر انتها به انتها ۱ میلی ثانیه و قابلیت اطمینان بالاتر از ۹۹,۹۹۹ درصد برای ارتباطات بسیار قابل اعتماد با تأخیر کم.
- تراکم ۱ میلیون در هر کیلومتر مربع برای کاربردهای اینترنت اشیا
- نرخ ارسال داده بالاتر از ۵۰ Mb/s برای کاربرد های باند وسیع
- دقت مکان یابی در ارتباط بین وسایل نقلیه

همه این‌ها به سمت شبکه‌های بی‌سیم با سطح بی‌سابقه‌ای از پیچیدگی می‌رود، که باعث می‌شود رویکردهای طراحی سنتی دیگر مناسب نباشند. برای مقابله با این حجم از پیچیدگی، رویکردهای متداول در طراحی سیستم باید به طور اساسی تجدید نظر شود. یک رویکرد پیشرو برای این منظور استفاده از یادگیری عمیق و شبکه‌های عصبی مصنوعی (ANN) است.

۱-۱ شبکه‌های بی‌سیم مبتنی بر هوش مصنوعی

چالش بحران پیچیدگی را می‌توان با هوشمند ساختن شبکه‌های بی‌سیم، به عنوان مثال، توانایی تعیین بهترین خط مشی به طور خودکار، با نیاز بسیار محدود به مداخله انسانی، حل کرد. این انگیزه ایجاد شبکه‌های بی‌سیم با قابلیت‌های هوش مصنوعی (AI) را فراهم می‌کند تا بتوانند بهترین سیاست را بر اساس تجربه به دست آمده از پردازش داده‌های قبلی تعیین کنند. با توجه به این نکته، باید به صراحت بیان کنیم که اگرچه رویکردهای داده محور نیاز به مدل‌های ریاضی برای طراحی و عملیات شبکه را

کاهش می‌دهد، اما مدل‌های ریاضی با وجود دست و پا گیر بودن یا عدم دقت، همچنان می‌توانند برای تکمیل استفاده شوند. و روش‌های صرفاً مبتنی بر داده را بهبود بخشد.

اما چگونه می‌توان هوش مصنوعی را در شبکه‌های بی‌سیم تعبیه کرد؟ چارچوبی که به این سمت می‌رود، یادگیری عمیق است، که یک تکنیک یادگیری ماشینی خاص است که فرآیند یادگیری را توسط شبکه‌های عصبی مصنوعی پیاده‌سازی می‌کند. اگرچه یادگیری عمیق محبوب‌ترین ابزار یادگیری ماشینی است و یک واقعیت تلفیقی در بسیاری از زمینه‌های علم است، اما اخیراً یادگیری عمیق برای شبکه‌های بی‌سیم پیشنهاد شده است. این به این دلیل بود که برخلاف سایر زمینه‌های علم، شبکه‌های بی‌سیم همیشه مدل‌سازی ریاضی مناسبی را پذیرفته‌اند که باعث می‌شود رویکردهای مبتنی بر داده‌ها به شدت ضروری نباشد. با این حال، همانطور که قبلاً ذکر کردیم، پیچیدگی روزافزون شبکه‌های بی‌سیم، رویکردهای مبتنی بر داده را جذاب‌تر و جذاب‌تر می‌کند. علاوه بر این، عوامل اخیر دیگری وجود دارد که استفاده از یادگیری عمیق را برای شبکه‌های بی‌سیم تسهیل می‌کند:

- افزایش تصاعدی دستگاه‌های بی‌سیم منجر به رشد متناظر داده‌های ترافیکی می‌شود که می‌تواند برای آموزش شبکه‌های عصبی مصنوعی مورد استفاده قرار گیرد.
- پیشرفت‌های مدرن در ظرفیت محاسباتی، مانند استفاده از واحدهای پردازش گرافیکی، اجرای الگوریتم‌های بزرگ‌تر و پیچیده‌تر را بسیار سریع‌تر ممکن می‌سازد.

استفاده از یادگیری عمیق در ارتباطات بی‌سیم نیز توسط بازیگران صنعت و همچنین توسط نهادهای نظارتی، مانند موسسه استانداردهای مخابرات اروپا، که یک گروه مشخصات صنعتی به نام هوش شبکه تجربی را فعال کرده است، و اتحادیه بین‌المللی مخابرات (ITU) پشتیبانی می‌شود. اخیراً ITU چارچوب معماری ITU-T Y.3172 را برای یادگیری ماشین در شبکه‌های آینده تأیید کرده است.

علیرغم همه این علایق و تلاش‌ها، برای تحقق چشم‌انداز شبکه‌های بی‌سیم مبتنی بر هوش مصنوعی، برخی مسائل حیاتی وجود دارد که باید درک شود. به طور مشخص:

- **اکتساب داده‌ها.** یادگیری عمیق به حجم زیادی از داده‌های آموزشی برای عملکرد خوب نیاز دارد. همانطور که قبلاً ذکر شد، این داده‌ها اکنون از طریق هوا در دسترس هستند، اما مکانیسم‌های خاص برای به دست آوردن، ذخیره و پردازش آن هنوز مشخص نیست. بخش بعدی مفهوم محیط‌های رادیویی هوشمند را مطرح می‌کند که مبتنی بر استفاده از مواد هوشمند نوآورانه هستند که به عنوان

متمایز مواد شناخته می‌شوند و توانایی‌های ارتباطی و همچنین ذخیره و پردازش داده‌ها را دارند. محیط‌های رادیویی هوشمند به عنوان یک راه حل امیدوارکننده برای شبکه‌های بی‌سیم واقعاً هوشمند ظاهر می‌شوند. علاوه بر این، یکی دیگر از روش‌های مفید برای کاهش مقدار داده‌های مورد نیاز، استفاده متقابل بین تکنیک‌های مبتنی بر داده و مبتنی بر مدل است.


- **استقرار شبکه‌های عصبی مصنوعی در شبکه‌های ارتباطی در حالی که به نظر می‌رسد واضح است که شبکه‌های ارتباطی آینده باید به هوش مصنوعی متکی باشند، مشخص نیست که شبکه‌های عصبی مصنوعی کجا و چگونه باید در شبکه‌های ارتباطی مستقر شوند. آیا داده‌های به دست آمده باید در یک مکان متمرکز ذخیره شوند، جایی که یک ANN واحد یک دامنه شبکه بزرگ را مدیریت می‌کند، یا هر دستگاه شبکه باید داده‌های خود را ذخیره کند و یک ANN محلی را اجرا کند؟ در بخش بعدی نیز به این نکته پرداخته شده است.**

فصل دوم

ادغام در شبکه های بی سیم: محیط های رادیویی هوشمند

همانطور که قبلاً پیش بینی شده بود، شبکه های بی سیم آینده خدماتی فراتر از ارتباطات بین افراد و اشیاء ارائه خواهند کرد. شبکه های بی سیم آینده به یک پلت فرم ارتباطی، سنجش و محاسباتی بی سیم هوشمند توزیع شده تبدیل خواهند شد که علاوه بر ارتباطات، قادر به سنجش محیط و همچنین ذخیره و پردازش داده ها خواهد بود. شبکه های بی سیم آینده برای غلبه بر چالش به هم پیوستن دنیای فیزیکی و دیجیتالی به شیوه ای یکپارچه و پایدار نیاز خواهند داشت.

همانطور که قبلاً ذکر شد، برای تبدیل چشم انداز شبکه های آینده به واقعیت، دیگر تکیه بر شبکه های بی سیم که عملیات منطقی آنها نرم افزار کنترل و بهینه سازی شده با رویکردهای سنتی است، کافی نیست. در عوض، خود محیط بی سیم باید هوشمند شود و بتواند خود را برای اطمینان از اتصال یکپارچه بهینه کند. ما از محیط بی سیم با این ویژگی ها به عنوان محیط رادیویی هوشمند یاد می کنیم.



شکل ۱-۱ شبکه های فعلی در مقابل یک محیط رادیویی هوشمند (یا بی سیم هوشمند)

دید ما در شکل ۲،۱ بهتر توضیح داده شده است. شبکه های بی سیم کنونی از پارادایم معروف شانون پیروی می کنند که بر اساس آن محیط بر حسب احتمالات انتقال داده مدل سازی می شود، (یعنی $\{y|x\}$ ، \Pr ، یا از پارادایم وینر، که طبق آن محیط همچنان داده می شود. اما اثر آن را می توان با استفاده از سیگنال های بازخورد کنترل کرد. در عوض، یک محیط رادیویی هوشمند با اشیاء محیطی مشخص می شود که پاسخ الکترومغناطیسی آنها می تواند به منظور تأثیر مطلوب بر سیگنال های الکترومغناطیسی طراحی شود. بنابراین، سیگنال ورودی و پاسخ اشیاء محیطی به امواج رادیویی را می توان به طور مشترک برای بهبود عملکرد بهینه کرد. به عنوان مثال، سیگنال ورودی به سمت یک شیء محیطی معین هدایت می شود، که با تغییر فاز بهینه شده مناسب، آن را به سمت گیرنده منعکس می کند. به نوبه خود، گیرنده نیز به سمت سیگنال ورودی هدایت می شود.

اما چگونه می توان چنین مفهوم آینده نگرانه ای را پیاده سازی کرد؟ چندین پیاده سازی ممکن از محیط های رادیویی هوشمند در حال ظهور هستند. با استفاده از سطوح هوشمند قابل تنظیم مجدد (RIS) به عنوان امیدوارکننده ترین رویکرد میتوان نام برد. سطوح هوشمند که متاسطح نیز نامیده می شوند،

ساختارهای دو بعدی نازکی هستند که از ماده خاصی به نام متا ساخته شده اند که می توان آن ها را مجدداً پیکربندی کرد تا بر روی امواج رادیویی ورودی به روشی قابل برنامه ریزی عمل کند. بنابراین، RIS پتانسیل افزایش قابلیت اطمینان انتقال و پردازش اطلاعات را دارد و در عین حال یک پلت فرم توزیع شده مناسب برای انجام سنجش، ذخیره سازی و محاسبات آنالوگ کم انرژی و کم پیچیدگی دارد.

۱-۲ نقش یادگیری عمیق در محیط های رادیویی هوشمند

اگر پس از معرفی پارادایم محیط های رادیویی هوشمند، اجازه دهید به ارتباط آن با یادگیری عمیق بپردازیم. هدف این بخش ارائه این ایده است که محیط رادیویی هوشمند و یادگیری عمیق در هم تنیده شده و یکدیگر را توانمند می کنند.

برای شروع، اجازه دهید در مورد اینکه چرا محیط های رادیویی هوشمند ادغام هوش مصنوعی را در شبکه های بی سیم امکان پذیر می کنند، بحث کنیم. همانطور که بحث شد، علاوه بر توانایی بهبود عملکرد ارتباطات، فراسطح ها همچنین قادر به درک محیط اطراف و ذخیره داده های حس شده هستند. این باعث می شود که سطوح متا به پلتفرم مناسبی برای جمع آوری و پردازش داده ها تبدیل شوند، که یک نیاز ضروری یادگیری عمیق است. به عبارت دیگر، فراسطح ها تار و پود شبکه های بی سیم آینده مبتنی بر هوش مصنوعی را فراهم می کنند. به دلیل استفاده فراگیر از متا سطوح، محیط های رادیویی هوشمند به طور طبیعی قادر خواهند بود مجموعه های داده بزرگی را از سیگنال هایی که از طریق شبکه های ارتباطی عبور می کنند، به دست آورند و از آنها استفاده کنند. از این نظر، محیط های رادیویی هوشمند عاملی برای اجرای شبکه های ارتباطی مبتنی بر هوش مصنوعی هستند.

از سوی دیگر، همانطور که قبلاً ذکر شد، محیط های رادیویی هوشمند امکان طراحی نه تنها استراتژی های ارسال و دریافت، بلکه عملکرد انتقال محیط را نیز فراهم می کنند. این به طور قابل توجهی مقدار متغیرهایی را که می توان بهینه کرد افزایش می دهد، که منجر به افزایش قابل توجه پیچیدگی محاسباتی مورد نیاز برای انجام طراحی می شود. در یک محیط رادیویی هوشمند، عملکرد هر شی محیطی یک متغیر بهینه سازی است، علاوه بر استراتژی های فرستنده و گیرنده. مدل سازی دقیق چنین سناریوی شبکه نوظهور و بهینه سازی آن در زمان واقعی، کاری بسیار چالش برانگیز به نظر می رسد، که با چارچوب های بهینه سازی

موجود در زمانی که کانال انتشار تغییر نمی کند قابل حل نیست.. علاوه بر این، نیازهای بازخورد محیط های رادیویی هوشمند نیز بسیار بالاتر از شرایط فعلی است.

علاوه بر این، نیازهای بازخورد محیط های رادیویی هوشمند نیز بسیار بیشتر از شبکه های بی سیم کنونی است که پیچیدگی فرآیند تخصیص منابع را بیشتر می کند و منجر به هزینه های سرشار قابل توجهی می شود. در این زمینه، همانطور که در ادامه این فصل به تفصیل نشان داده خواهد شد، استفاده از یادگیری عمیق می تواند برای ساده کردن کار مدیریت منابع مفید باشد. از این نظر، یادگیری عمیق محیط های رادیویی هوشمند را قادر می سازد و بهینه سازی آنها را از نظر پیچیدگی محاسباتی امکان پذیر می سازد. همانطور که در بخش ۴ با اشاره به مطالعه موردی خاص به حداکثر رساندن بهره وری انرژی، ادغام رویکردهای مبتنی بر مدل و ابزارهای یادگیری عمیق نشان داده خواهد شد، می توان طرح های تقریباً بهینه شبکه های بی سیم پیچیده را با پیچیدگی مقرون به صرفه به دست آورد. با توجه به جنبه کارآمد انرژی، این حداقل دو مزیت عمده خواهد داشت که در ادامه این فصل به عنوان مثال توضیح داده خواهد شد.

- ساده سازی کار مدیریت منابع، امکان به حداکثر رساندن موثر بهره وری انرژی شبکه های پیچیده را فراهم می کند، حتی در سناریوهایی که با تکنیک های بهینه سازی کنونی بیش از حد پیچیده در نظر گرفته می شوند. پیش بینی می شود که بازده انرژی نقاط عملیاتی شبکه های بی سیم آینده را به میزان قابل توجهی افزایش دهد.
- حتی در سناریوهایی که بهینه سازی بازده انرژی تقریباً بهینه توسط رویکردهای بهینه سازی سنتی امکان پذیر است، استفاده از یادگیری عمیق می تواند پیچیدگی محاسباتی را کاهش دهد، بنابراین صرفه جویی قابل توجهی در انرژی در پردازشگر سیگنال دیجیتال ایجاد می کند.

۲-۲) استقرار شبکه های عصبی در شبکه های بی سیم

به منظور استفاده موفقیت آمیز از یادگیری عمیق برای ارتباطات بی سیم، یک سوال کلیدی این است که چگونه ANN ها را در توپولوژی شبکه های بی سیم موجود و آینده ادغام کنیم. در واقع کارآمدترین راه برای ذخیره و پردازش داده هایی که باید توسط شبکه های عصبی مصنوعی استفاده شود چیست؟ این سؤالی است که مختص شبکه های بی سیم است، به این معنا که در سایر زمینه های کاربردی یادگیری

عمیق، رویکرد معمول داشتن یک «مغز مصنوعی» متمرکز است که وظیفه‌ی مورد نظر را انجام می‌دهد. با این حال، این راه حل ایده آل در زمینه بی سیم عملی نیست، زیرا شبکه های بی سیم دارای الزامات خاصی هستند که باید برآورده شوند. به طور خاص، یک "مغز مصنوعی" متمرکز که بر مدیریت کل شبکه نظارت می‌کند و اقداماتی را که باید کاربران لبه ای انجام دهند را دیکته می‌کند، حداقل به دلیل نکات عمده زیر مشکل ساز است:

(۱) **تاخیر.** یکی از اهداف اصلی شبکه‌های بی سیم 5G آینده کاهش تأخیر ارتباط انتهایی است که برای برخی از برنامه‌ها باید کمتر از میلی ثانیه باشد. بنابراین، اگر قرار باشد این محدودیت برآورده شود، نمی‌توان منتظر ابر ماند. برای انجام محاسبات و سپس بازخورد نتایج، در عوض، محاسبات باید به صورت محلی توسط هر یک از تجهیزات کاربر (UE) انجام شود.

(۲) **حریم خصوصی.** حریم خصوصی و امنیت ارتباطات بی سیم مسائلی حیاتی برای تبدیل چشم انداز 5G از "دنیای متصل به همه چیز" به واقعیت خواهد بود. این بدان معناست که برای برخی از برنامه‌های کاربردی عمودی، اشتراک گذاری اطلاعات با ابر مطلوب نیست، که باعث می‌شود یادگیری عمیق مبتنی بر ابر امکان پذیر نباشد.

(۳) **قابلیت اتصال** یکی از اهداف اصلی شبکه های 5G آینده، ارائه اتصال در همه جا و هر زمان است. این یک هوش مصنوعی مبتنی بر ابر را مشکل ساز می‌کند، زیرا باعث می‌شود دستگاه لبه‌ای بیش از حد به ابر متکی باشد، حتی زمانی که اتصال قابل اعتمادی وجود ندارد. در عوض، پایانه‌های سیار باید دارای مقداری «هوش محلی» باشند تا بتوانند در این سناریوها نیز کار کنند.

در نتیجه، مانند جامعه بشری که هم یک هوش جمعی مشترک وجود دارد و هم یک هوش فردی وجود دارد، شبکه‌های بی سیم باید دارای هوش ابری باشند که باید برای همه گره‌ها قابل دسترسی باشد، و همچنین هوشمندی دستگاهی که به هر دستگاه جداگانه تعلق دارد. واضح است که این موضوع چندین مسئله را ایجاد می‌کند که برای اجرای موفقیت آمیز بودن شبکه های بی سیم مبتنی بر هوش مصنوعی باید مورد توجه قرار گیرد. اعطای قابلیت‌های هوش مصنوعی به هر گره شبکه نه تنها بر فناوری‌های انتقال تأثیر می‌گذارد، بلکه بر نحوه کنترل شبکه از طریق سیگنال‌های بازخورد نیز تأثیر می‌گذارد که از بی‌ثباتی و عملکرد نادرست جلوگیری می‌کند. در سناریویی که در آن هر گره شبکه "مغز" خود، یعنی ANN خود را دارد، تعاملات بین دستگاه‌های مختلف باید به دقت مورد

مطالعه قرار گیرد و مکانیسم هایی برای جلوگیری از اختلالات عملکرد، ناسازگاری داده ها و خرابی های سیستم ابداع شود.

فصل سوم

بهینه سازی بهره‌وری انرژی با یادگیری عمیق

این بخش دو مطالعه موردی را ارائه می کند که نشان می دهد چگونه می توان از یادگیری عمیق در ارتباط با رویکردهای ریاضی سنتی برای انجام طراحی شبکه بی سیم با انرژی کارآمد استفاده کرد. دو نوع برنامه مورد بحث قرار خواهد گرفت. اولین مورد موردی را در نظر می گیرد که در آن مسئله تخصیص منابع موجود، یک فرمول ریاضی دقیق را می پذیرد، که با این حال، آنقدر پیچیده است که با پیچیدگی عملی قابل حل نیست. در عوض، رویکرد دوم وضعیتی را در نظر می گیرد که در آن هیچ مدل ریاضی دقیقی برای مسئله مورد نظر در دسترس نیست، که مستلزم استفاده از مدل های تقریبی است.

رویکرد مقابله با سناریوی اول مبتنی بر این ویژگی است که ANN ها تقریبگرهای تابع جهانی هستند، به عنوان مثال، نقشه ورودی-خروجی آنها را می توان تنظیم کرد تا هر نقشه پیوسته را شبیه سازی کند. این ویژگی را می توان با مشاهده این که هر مسئله تخصیص منبع را می توان به عنوان یک نقشه از مجموعه همه پارامترهای مورد علاقه شبکه، که با $\mathbf{d} \in \mathbb{R}^N$ نشان داده شده است، به تخصیص بهینه منبع $\mathbf{X}^* \in \varphi$ در نظر گرفت و φ نشان دهنده مجموعه شدنی است. تخصیص منابع به طور رسمی به صورت زیر است:

$$\Phi: \mathbf{d} \in \mathbb{R}^N \rightarrow \mathbf{X}^* \in \varphi \subseteq \mathbb{S}. \quad (1)$$

بنابراین، شبکه های عصبی را می توان آموزش داد تا نقشه ناشناخته F را شبیه سازی کند. این کار امکان بهینه سازی یک تابع عملکرد مطلوب را برای پارامترهای سیستم داده شده بدون نیاز به حل صریح مسئله تخصیص منبع با روش های بهینه سازی عددی، بلکه با استفاده از شبکه عصبی آموزش دیده که پارامترهای وضعیت کنونی شبکه را به عنوان ورودی دریافت می کند و روش تخصیص منابع بهینه را به عنوان خروجی بدهد. این مزیت بزرگی دارد که هر زمان که پارامترهای سیستم تغییر می کنند، نیازی به حل دوباره یک مسئله بهینه سازی نیست، اما کافی است ورودی ANN را تغییر دهیم، که خروجی را با استفاده از یک انتشار ساده رو به جلو محاسبه می کند.

از سوی دیگر، این رویکرد مستقیماً برای سناریوی دوم اعمال نمی شود، زیرا هیچ مدل قابل اعتمادی در دسترس نیست. با این حال، اگر فقط یک مدل تقریبی در دسترس باشد، همچنان می توان از آن برای پیش آموزش یک ANN با همان رویکردی که قبلاً ذکر شد، استفاده کرد. در مرحله بعد، پیکربندی ANN را می توان با استفاده از مرحله دوم آموزشی که در دسترس بودن مجموعه آموزشی حاوی نمونه های داده

های تجربی را فرض می کند و ابزارهایی را از تئوری یادگیری انتقال به کار می گیرد، اصلاح کرد. جزئیات هر دو رویکرد به تفصیل در ادامه این بخش توضیح داده شده است.

۳-۱) به حداکثر رساندن بازده انرژی جمع وزنی

یکی از الزامات کلیدی شبکه های بی سیم آینده افزایش چشمگیر بازده انرژی جهانی است که به صورت بیت هایی که به طور قابل اعتمادی از طریق ژول انرژی مصرف شده منتقل می شوند اندازه گیری می شود. بر این اساس، اجازه دهید لینک آپلود یک شبکه چند سلولی M ایستگاه پایه (BS) و K کاربر موبایل را در نظر بگیریم. هر BS مجهز به N آنتن است، در حالی که کاربران تلفن همراه دارای یک آنتن هستند. فرض کنید $\mathbf{h}_{k,m}$ یک کانال $1 \times N$ از کاربر k به ایستگاه پایه m باشد، p_k توان ارسال k امین کاربر، \mathbf{c}_k بردار دریافتی برای کاربر k ، و σ_m^2 توان نویز دریافتی در ایستگاه پایه m باشد. بنابراین، SINR که کاربر k در گیرنده مورد نظر خود m_k دارد به صورت زیر است:

$$\gamma_k = \frac{p_k |\mathbf{c}_k^H \mathbf{h}_{k,m_k}|^2}{\sigma^2 + \sum_{j \neq k} p_j |\mathbf{c}_j^H \mathbf{h}_{j,m_k}|^2} = \frac{p_k d_{k,k}}{\sum_{j \neq k} p_j d_{k,j}}. \quad (2)$$

$$\text{with } d_{k,j} = |\mathbf{c}_j^H \mathbf{h}_{j,m_k}|^2, \text{ for all } k, j.$$

بر اساس (2)، بازده انرژی جمع وزنی شبکه (WSEE) توسط

$$WSEE = \sum_{k=1}^K w_k \frac{B \log_2(1 + \gamma_k)}{P_{c,k} + \mu_k p_k} \left(\frac{\text{bit}}{J} \right). \quad (3)$$

که در آن B پهنای باند ارتباطی است، $P_{c,k}$ مصرف برق استاتیک سخت افزاری لینک ارتباطی k ام، μ_k معکوس بازده تقویت کننده توان فرستنده k ام است، و w_k وزنی غیرمنفی است که اهمیت داده شده به بازده انرژی لینک k ام را مدل سازی می کند. لازم به ذکر است که $P_{c,k}$ به پارامترهای سیستم مانند تعداد آنتن و کارایی اجزای سخت افزاری سیستم بستگی دارد، اما فرض بر این است که به توان های ارسال بستگی ندارد و بنابراین مدل خاصی که $P_{c,k}$ را به صورت یک تابع از اجزای سخت افزاری سیستم بیان می کند تا آنجا که به حداکثر کردن (۳) به عنوان تابعی از قدرت های انتقال مربوط می شود، ضروری نیست.

به حداکثر رساندن WSEE سخت ترین نوع مشکلات به حداکثر رساندن کارآمد انرژی در نظر گرفته می شود. در واقع، مجموع کسری ها به طور کلی غیرچند جمله ای سخت (NP-hard) هستند و بنابراین نمی توان با پیچیدگی چند جمله ای با هیچ تکنیک برنامه نویسی کسری موجود مقابله کرد. علاوه بر این، هر صورت کسر از مجموع WSEE مقعر نیست. این نشان می دهد که حتی مورد خاص ساده تر از حداکثر کردن نرخ جمع وزنی (تنظیم $\mu_i = 0$ برای همه $i = 1, 2, \dots, L$) یک مسئله NP-hard است. بنابراین، نشان دادن اینکه شبکه های عصبی مصنوعی می توانند مسئله حداکثر کردن (۳) را حل کنند، انگیزه ای قوی برای استفاده از آن برای حل مشکلات ساده تر نیز نشان می دهد، مانند حداکثر کردن نرخ جمع سیستم. علاوه بر این، برخلاف معیارهای کارآمدی انرژی در سراسر سیستم مانند بازدهی انرژی جهانی، WSEE امکان اولویت بندی بازدهی انرژی تک تک کاربران را از طریق انتخاب وزن های $w_i \geq 0$ فراهم می کند. این ممکن است در مواردی مفید باشد که برخی از کاربران به راندمان انرژی بالاتری نیاز دارند همچون کاربرانی که از روش برداشت انرژی نیرو می گیرند.

بنابراین، مسئله کنترل توان به عنوان ماکزیمم WSEE در معرض محدودیت های توان بیان می شود، یعنی:

$$\max_{\{p_k\}_{k=1}^K} WSEE(p_1, \dots, p_K) \quad (4 \cdot a)$$

$$\text{s.t. } P_{\min.k} \leq p_k \leq P_{\max.k}, \forall k = 1, \dots, K. \quad (4 \cdot b)$$

که $P_{\min.k}$ و $P_{\max.k}$ حداکثر توان قابل انتقال و حداقل توان قابل قبول برای کاربر k است. مسئله (۴) یک مسئله به اصطلاح جمع نسبت است که سخت ترین کلاس مسائل کسری در نظر گرفته می شود. علاوه بر این، دشواری (۴) با این واقعیت افزایش می یابد که صورت های کسری به دلیل وجود تداخل چند کاربره توابع مقعر نیستند. در نتیجه، یک ANN می تواند نقشه بهینه بین کانال های سیستم را بیاموزد و بردار توانی (۴) حل کند، که یک مورد بسیار قوی به نفع استفاده از یادگیری عمیق برای تخصیص منابع با انرژی کارآمد در شبکه های بی سیم ایجاد می کند.

در حال حاضر، برای حل (۴)، تنها روش های بهینه سازی سراسری در دسترس هستند، در حالی که رویکردهای عملی تر تنها بهینه بودن مرتبه اول را تضمین می کنند. علاوه بر این، همانطور که قبلاً ذکر شد، اگر از روش های تخصیص منابع سنتی استفاده می شد، هر زمان که تحقق کانال $\{h_{\ell.m_k}\}_{k,\ell}$ تغییر کند، مسئله (۴) باید دوباره حل شود. این به وضوح یک اشکال اساسی است که از استفاده از رویکرد نظری بهینه

سازی برای تخصیص منابع آنلاین جلوگیری می کند، یعنی به دنبال تغییرات در مقیاس کوچک ضرایب کانال. در واقع، توان انتقال بهینه باید قبل از پایان زمان انسجام کانال محاسبه شود تا عملاً مفید باشد. در عوض، با اتخاذ یک رویکرد مبتنی بر شبکه عصبی مصنوعی، مسئله کنترل توان را به صورت نقشه مجهول از ضرایب $\{h_{\ell.m_k}\}_{k,\ell}$ و حداکثر/حداقل توان انتقال P_{mix} و P_{max} مدل سازی می کنیم تا بردار تخصیص توان بهینه p^* که به صورت زیر حاصل شود:

$$\mathcal{F}: \mathbf{d} = \{d_{k,\ell}, P_{min,k}, P_{max,k}\}_{k,\ell} \in \mathbb{R}^{K(M+2)} \rightarrow p^* \in \mathbb{R}^K \quad (5)$$

سپس یک شبکه عصبی را آموزش دهید تا رابطه ورودی-خروجی آن نقشه ناشناخته را بازتولید کند (۵). این منجر به در نظر گرفتن یک ANN با $K(M+2)$ گره ورودی و K گره خروجی می شود تا آموزش داده شود تا بردار $K \times 1$ توان بهینه p^* مربوط به $K(M+2) \times 1$ ورودی داده شده حاصل شود. به طور خاص، با بهره برداری از مدل ریاضی نشان داده شده توسط مسئله (۴) می توان یک مجموعه آموزشی با حل بسیاری از نمونه های مسئله (۴) به صورت آنلاین تولید کرد، که مربوط به بسیاری از تحقیقات مختلف پارامترهای سیستم \mathbf{d} است. در این مرحله، شبکه عصبی در نظر گرفته شده را می توان با هر الگوریتم آموزشی برای یادگیری نقشه بهینه در (۵) آموزش داد. پس از مرحله آموزش، شبکه عصبی آموزش دیده شده را می توان به صورت آنلاین برای استنباط تخصیص منابع مورد نظر مربوط به هر پیکربندی سیستم به سادگی با انجام انتشار رو به جلو استفاده کرد. بنابراین، چارچوب تخصیص منابع مبتنی بر ANN پیشنهادی را می توان به دو مرحله تقسیم کرد که در ادامه توضیح داده می شود:

۱. فاز آفلاین در طول این مرحله، ANN آموزش داده و پیکربندی می شود. باید تاکید کرد که هم تولید مجموعه آموزشی و هم اجرای الگوریتم آموزشی می توانند به صورت آفلاین و فقط به صورت پراکنده، یعنی در مقیاس زمانی بسیار طولانی تر از نرخ تغییر پارامترهای شبکه انجام شوند. بنابراین، پیچیدگی این مرحله در دراز مدت ناچیز می شود. علاوه بر این، یک چارچوب بهینه سازی اخیراً پیشنهاد شده که به طور قابل توجهی تولید مجموعه آموزشی را برای سائل تخصیص منابع بهینه انرژی ساده می کند.

۲. فاز آنلاین. پس از آموزش ANN، شبکه به صورت آنلاین برای استنباط تخصیص بهینه منابع مربوط به هر گونه تحقق کانال های سیستم استفاده می شود. این مرحله بارها برای هر مرحله آفلاین تکرار می شود، یعنی برای هر بلوک همدوس که ANN باید دوباره آموزش داده شود. در هر بلوک همدوس، تحقق کانال فعلی ورودی ANN است، و توان های مربوطه با انجام یک انتشار

رو به جلو محاسبه می شوند. این به تعداد $N_{\ell-1} N_{\ell}$ ضرب حقیقی و تعداد $\sum_{\ell=1}^{L+1}$ ارزیابی نیاز دارد. که N_{ℓ} تعداد نورون‌ها در لایه ℓ ام و L تعداد لایه‌های مخفی است.

باید تاکید کرد که این رویکرد کاملاً مبتنی بر داده نیست، بلکه نمونه ای از بارورسازی متقابل بین رویکردهای مبتنی بر داده و مدل را نشان می‌دهد. در واقع، در موردی که در دست است، مدلی از مسئله برای حل توسط مسئله (۴) ارائه می‌شود و به ما اجازه می‌دهد به سادگی یک مجموعه آموزشی بدون نیاز به اندازه‌گیری میدانی تولید کنیم. مشکل این است که حل مشکل (۴) با پیچیدگی سازگار با یک پیاده سازی آنلاین بسیار سخت است، و اینجاست که یادگیری عمیق مفید بوده است.

تحلیل عملکرد عددی. این بخش نتایج عددی را برای نشان دادن عملکرد روش توصیف شده ارائه می‌دهد. آپلود یک شبکه تداخل بی سیم با $K = 4$ UE تک آنتن که در یک منطقه مربع با لبه ۲ کیلومتر و ارتباط با چهار نقطه دسترسی قرار گرفته در مختصات $(0, 5)$ ، $(1, 5)$ ، $(0, 5)$ و $(1, 5)$ را در نظر بگیرید. هر یک از نقاط دسترسی مجهز به $nR = 2$ آنتن می‌باشد. با فرکانس حامل ۱٫۸ گیگاهرتز و ضریب کاهش توان برابر با ۴٫۵، در حالی که محوشوندگی سریع به عنوان تحقق متغیرهای تصادفی گاوسی پیچیده دایره‌ای متقارن با میانگین صفر مدل‌سازی می‌شوند. علاوه بر این، $P_{c,k} = 1W$ و $\mu_k = 4$ برای همه $k = 1 \dots K$ ، در حالی که قدرت نویز در هر گیرنده $\sigma^2 = F N_0 B$ است، با $F = 3dB$ رقم نویز گیرنده، $B = 180kHz$ پهنای باند ارتباطی، و $N_0 = -174dBm/Hz$ چگالی طیفی نویز است. حداکثر توان ارسال برای همه کاربران یکسان است، یعنی $P_{max,1} = \dots = P_{max,K} = P_{max}$ ، در حالی که $P_{min,k} = 0$ برای همه $k = 1 \dots K$ می‌باشد.

راه‌حل مبتنی بر ANN مسئله (۴) با استفاده از یک ANN پیش‌خور با $L+1$ لایه کاملاً متصل، که هر $L = 5$ لایه پنهان به ترتیب دارای ۱۲۸، ۶۴، ۳۲، ۱۶، ۸ نورون هستند، اجرا می‌شود. پس از تولید مجموعه آموزشی با حل مسئله (۴) برای تحقق‌های مختلف بردار d ، تحقق بردارهای پارامتر d و توان‌های خروجی بهینه در مجموعه آموزشی به واحدهای لگاریتمی تبدیل شده است که مشکلات عددی در طول دوره آموزش را کاهش می‌دهد. اجرای الگوریتم آموزشی علاوه بر این، به منظور اجتناب از مشکلات عددی ناشی از محاسبه لگاریتم مقادیر توان ارسال که بسیار نزدیک به صفر هستند، مقادیر $-M$ برای $M > 0$ بریده شده است. در آزمایش‌های ما، $M = 20$ کار کرد. بنابراین، مجموعه آموزش نرمال شده در نظر گرفته شده است.

$$\mathcal{S}_T = \{(\log_{10} d_n \cdot \max\{-20 \cdot \log_{10} \tilde{p}_n^*\}) \mid n = 1 \dots N_T\}$$

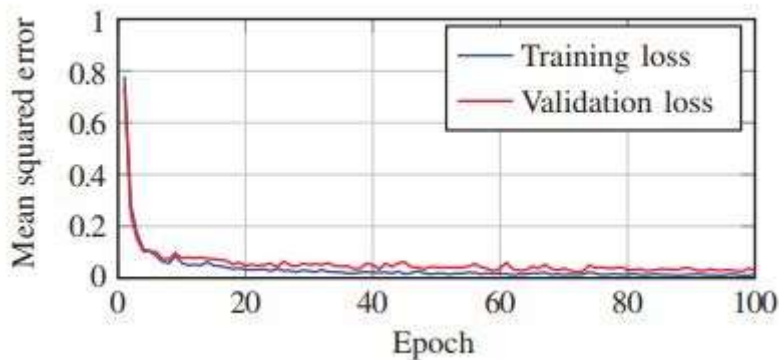
که در آن همه توابع به هر یک از بردار مجموعه آموزشی اعمال می‌شوند.

توابع فعال‌سازی روی واحد خطی نمایی (ELU) برای اولین لایه پنهان تنظیم شده‌اند، در حالی که لایه‌های پنهان بعدی توابع فعال‌سازی ReLU و ELU را جایگزین می‌کنند و لایه خروجی از یک تابع فعال‌سازی خطی استفاده می‌کند. استفاده از یک فعال‌سازی خطی در لایه خروجی با توجه به این که به ANN اجازه می‌دهد تا به جای کاهش مصنوعی خطای خروجی به دلیل استفاده از برش، خطای آموزشی کم را در نتیجه پیکربندی مناسب لایه‌های پنهان ایجاد کند. به عبارت دیگر، یک تابع فعال‌سازی خروجی خطی به ANN اجازه می‌دهد تا یاد بگیرد که آیا پیکربندی فعلی وزن‌ها و بایاس‌ها واقعاً منجر به یک خطای خروجی کوچک می‌شود یا خیر.

ANN در Keras 2.2.4 با TensorFlow 1.12.0 به عنوان backend، با استفاده از مقداردهی اولیه یکنواخت Glorot، الگوریتم آموزش آدام با تکانه Nesterov، و خطای میانگین مربع به عنوان تابع ضرر پیاده‌سازی شده است. آموزش با حل مسئله (۴) برای ۱۰۲۰۰۰ تحقق مستقل و توزیع شده یکسان از موقعیت‌های UEs و کانال‌های انتشار و مقادیر مختلف Pmax به دست می‌آید. در هر سناریو، UEها با نقطه دسترسی که به سمت آن از قوی‌ترین کانال موثر برخوردار هستند، مرتبط هستند. یک مجموعه اعتبارسنجی و یک مجموعه آزمایشی به ترتیب ۱۰۲۰۰ و ۵۱۰۰۰۰ نمونه نیز به روش مشابه ایجاد شد.

با در نظر گرفتن مجموعه‌های آموزش، اعتبارسنجی و آزمون، ۶۲۲۲۰۰ نمونه داده تولید شده که نیاز به 622200 بار حل مسئله (4) NP-hard داشت. این کار ۸٫۴ ساعت CPU در گره‌های Haswell اینتل با پردازنده‌های Xeon E5-2680 v3 که با فرکانس ۲٫۵۰ گیگاهرتز کار می‌کنند، با استفاده از روش شاخه و کران بهبود یافته طول کشیده است. بنابراین، میانگین زمان مورد نیاز برای حل بهینه یک نمونه از مسئله حداکثرسازی WSEE، $\bar{T} = 4.86 \times 10^{-2} s$ ثانیه است. از سوی دیگر، انتشار رو به جلو ANN در نظر گرفته شده به ۱۰۹۱۲ ضرب واقعی و ۲۵۲ ارزیابی تابع فعال‌سازی نیاز دارد. بنابراین، ۱۱۱۶۴ عملیات ابتدایی برای انتشار رو به جلو مورد نیاز است، که با توجه به فرکانس ساعت ۲٫۵۰ گیگاهرتز رایانه مورد استفاده برای اجرای شبیه‌سازی‌های ما، زمان متوسطی را برای حل یک نمونه از مشکل حداکثرسازی $\bar{T} = 4.47 \mu s$ WSEE زمان نیاز است. چهار مرتب کوچکتر از روش بهبود یافته شاخه و کران است.

این به وضوح نشان می دهد که چگونه تولید آفلاین یک مجموعه آموزشی مناسب برای کنترل توان مبتنی بر ANN کاملاً مقرون به صرفه است. در نهایت، تمام نتایج عملکرد گزارش شده با به دست آمدن میانگین بیش از ده تحقق شبکه به دست آمده از آموزش ANN در مجموعه آموزشی مشابه با مقداردهی اولیه متفاوت مولد اعداد تصادفی زیربنایی به دست آمده اند. میانگین تلفات آموزش و اعتبارسنجی برای ANN نهایی در شکل ۲ نشان داده شده است. می توان مشاهده کرد که هم خطاها به سرعت کاهش می یابند و هم به مقدار بسیار کمی نزدیک می شوند. بنابراین نشان می دهد که پیکربندی ANN اتخاذ شده قادر است به درستی داده های آموزشی را بدون بیش برآزش یا بایاس آموزش دهد.



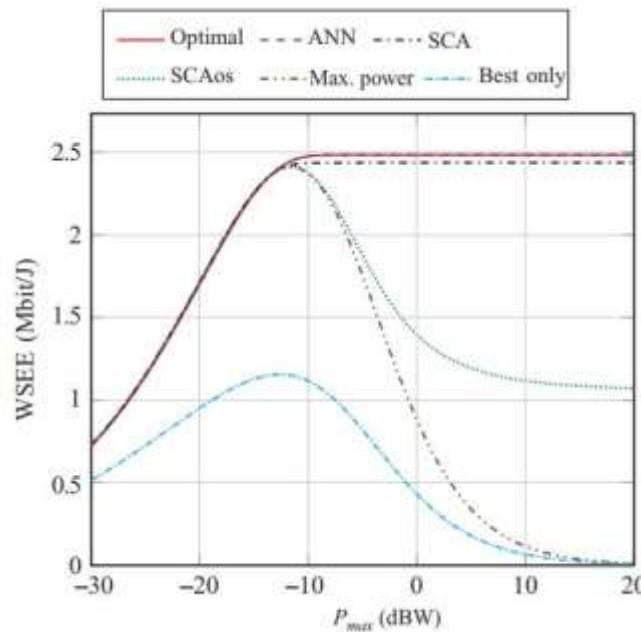
شکل ۲-۱ تلفات آموزشی و اعتبارسنجی در مقابل عدد دوره آموزشی. مشاهده می شود که پس از مرحله آموزش، شبکه ANN دچار **overfitting** و **underfitting** نشده است.

در مرحله بعد، عملکرد روش پیشنهادی را در مجموعه آزمایشی ارائه می کنیم و روش مبتنی بر ANN پیشنهادی را با معیارهای زیر مقایسه می کنیم:

- **SCAos**: یک روش بهینه مرتبه اول که از روش های تقریب محدب متوالی (SCA) استفاده می کند. برای هر مقدار P_{max} ، الگوریتم توان انتقال را به $p_i = P_{max}$ ، به ازای $k = 1, \dots, K$ مقداردهی می کند.

- **SCA**: مجدداً روش بهینه مرتبه اول مبتنی بر تقریب محدب متوالی استفاده می شود، اما با رویکرد مقداردهی اولیه دوگانه. به طور خاص، در $P_{max} = -30\text{dBW}$ مقدار اولیه حداکثر توان استفاده می شود. با این حال، برای تمام مقادیر $P_{max} = -30\text{dBW}$ ، الگوریتم دو بار اجرا می شود، ابتدا با مقدار اولیه حداکثر توان، و سپس با مقدار بهینه به دست آمده برای مقدار قبلی P_{max} ، توان های ارسال را مقداردهی اولیه می کند. و در نهایت، تخصیص توان با WSEE بهتر در نظر گرفته می شود.

- حداکثر توان: همه UE ها با حداکثر توان ارسال می کنند، یعنی $p_k = P_{max}$ ، برای همه $k = 1, \dots, K$. این استراتژی در شبکه های تداخلی برای مقادیر کم P_{max} به خوبی عمل می کند.
- فقط بهترین: فقط یک UE مجاز به انتقال است، یعنی UE با بهترین کانال موثر. این رویکرد برای مقادیر بالای P_{max} ، به عنوان یک روش ساده برای از بین بردن تداخل چند کاربر معرفی شده است.



شکل ۳-۲ عملکرد WSEE روش مبتنی بر ANN پیشنهادی در مقایسه با بهینه جهانی و چندین الگوریتم پیشرفته

نتایج در شکل ۳-۲ نشان می دهد که رویکرد مبتنی بر ANN از تمام رویکردهای عملی دیگر بهتر عمل می کند. تنها معیاری که عملکرد قابل مقایسه با رویکرد مبتنی بر ANN دارد، الگوریتم SCA است که از قاعده مقدار دهی اولیه پیچیده که نیاز به دو بار حل مسئله حداکثرسازی WSEE و برای کل مقادیر P_{max} دارد، استفاده می کند. بنابراین، رویکرد SCA بسیار پیچیده تر از روش مبتنی بر ANN است، اما، با وجود این، کمی بدتر عمل می کند. در نتیجه، می توانیم استدلال کنیم که رویکرد ANN نسبت به روش های پیشرفته، از نظر عملکرد و پیچیدگی بسیار بهتری از سایر روش ها عمل می کند و بنابراین تخصیص توان آنلاین را در شبکه های ارتباطی بی سیم ممکن می سازد.

۲-۳) بهره وری انرژی در شبکه های بی سیم غیر پواسون: رویکرد یادگیری انتقال

عمیق

مثال قبلی فرض می کند که یک مدل ریاضی از مسئله در دسترس است تا به ما اجازه دهد تا مسئله بهینه سازی را فرموله کنیم. مشکل در دست و پا گیر بودن مدل نهفته است. در عوض، این بخش سناریوهای مختلفی را در نظر می گیرد که در آن فقط مدل های تقریبی در دسترس هستند، در حالی که مدل های به اندازه کافی دقیق وجود ندارند. به طور خاص، مسئله بهینه سازی بازده انرژی با توجه به چگالی ایستگاه های پایه، در شبکه های سلولی غیر پواسون را در نظر بگیرید، که به دلیل پیچیدگی تحلیلی $utility\ function$ برای بهینه سازی، به عنوان یک مسئله بهینه سازی غیر قابل حل شناخته شده است. در این مورد، رویکرد استفاده شده در بخش قبل به طور مستقیم اعمال نمی شود. با این حال، می توان آن را با ادغام با چارچوب یادگیری انتقال عمیق به این مورد تعمیم داد.

یادگیری انتقالی یک چارچوب یادگیری ماشین است که ابزارهایی را برای انتقال دانش به دست آمده در هنگام حل یک کار مشخص و استفاده از آن برای حل یک کار جدید، اما مرتبط، بدون شروع فرآیند یادگیری از ابتدا ارائه می کند. این مفهوم کلی را می توان به روش های مختلفی اعمال کرد، اما در اینجا ما رویکردی را دنبال می کنیم که به عنوان یادگیری انتقال مبتنی بر شبکه شناخته می شود، که بدین صورت کار می کند که ابتدا شبکه بی سیم را بر اساس مدل سازی ناقص، اما ساده تر برای بهینه سازی، و سپس اصلاح این بهینه سازی نادرست انجام می دهد. با یک رویکرد کاملاً مبتنی بر داده بر اساس چند نمونه تجربی. این ایده کلی را می توان برای مسئله خاص ما به عنوان رویکرد دو مرحله ای زیر اعمال کرد.

ابتدا، فرض می کنیم که گره ها در شبکه بی سیم به صورت فرآیند نقطه پواسون توزیع می شوند، در حالی که مدل فرآیند نقطه واقعی، مدل شبکه مربعی فرض می شود. این یک مثال ساده ای است که به منظور روشن کردن رویکرد پیشنهادی ما انتخاب شده است، و همچنین شبیه سازی و بازتولید آن آسان است. سپس، با استفاده از فرض پواسون، EE شبکه را می توان به صورت بسته بهینه کرد. این امر تولید یک مجموعه آموزشی بزرگ از مقادیر بهینه برای EE را به عنوان تابعی از پارامترهای سیستم بسیار ساده می کند، که سپس برای آموزش یک ANN، با پیروی از رویکردی مشابه در بخش قبل، استفاده می شود. بنابراین، این گام اول یک پیکربندی ANN آزمایشی را به دست می دهد که به دلیل عدم تطابق با شبکه بی سیم پواسون است ناقص است.

در مرحله بعد، ما فرض می کنیم که مجموعه آموزشی دوم در دسترس است، که فقط باید حاوی چند داده باشد، اما بر اساس اندازه گیری های واقعی. به عبارت دیگر، یک مجموعه داده دوم و کوچکتر از داده های تجربی برای اصلاح پیکربندی ANN مورد نیاز است. به طور خاص، این مجموعه داده برای انجام مرحله آموزشی دوم استفاده می شود، که در آن، به جای استفاده از مقداردهی اولیه تصادفی، وزن ها و بایاس های ANN با مقادیر به دست آمده پس از مرحله آموزش اول مقداردهی می شوند. به عبارت دیگر، ایده پشت این رویکرد استفاده از مرحله آموزش اول برای به دست آوردن یک نقطه اولیه کارآمد برای مرحله دوم آموزش است. البته برای اینکه این موضوع درست باشد، باید عدم تطابق بین مدل تقریبی و مدل واقعی شبکه خیلی زیاد نباشد.

بقیه این بخش جزئیات بیشتر و مثال های عددی را برای نشان دادن مزایای رویکرد توصیف شده ارائه می کند.

بهینه سازی مبتنی بر مدل. EE در شبکه های سلولی پواسون را می توان به صورت زیر فرموله کرد:

$$EE(\lambda_{BS}) = \frac{SE(\lambda_{BS})}{P_{grid}(\lambda_{BS})} \quad (6)$$

که در آن

$$SE(\lambda_{BS}) = B_W \log_2(1 + \gamma_D) \frac{\lambda_{BS} L \left(\frac{\lambda_{MT}}{\lambda_{BS}} \right)}{1 + \gamma L \left(\frac{\lambda_{MT}}{\lambda_{BS}} \right)} \times Q \left(\lambda_{BS} \cdot P_{tx} \cdot \frac{\lambda_{MT}}{\lambda_{BS}} \right) \quad (7)$$

$$P_{grid}(\lambda_{BS}) = \lambda_{BS} P_{tx} L \left(\frac{\lambda_{MT}}{\lambda_{BS}} \right) + \lambda_{MT} P_{circ} + \lambda_{BS} P_{idle} \left(1 - L \left(\frac{\lambda_{MT}}{\lambda_{BS}} \right) \right) \quad (8)$$

به ترتیب راندمان طیفی و توان مصرفی شبکه سلولی می باشد.

معادلات (۷) و (۸) به پارامترهای زیادی بستگی دارند. اما توجه به این نکته کافی است که λ_{BS} چگالی استقرار BS ها، P_{tx} توان انتقال BS ها، P_{circ} مصرف برق مدار BS ها، و P_{idle} مصرف برق در بیکاری BS ها است. در سرتاسر این بخش، P_{idle} و P_{circ} ثابت فرض می شوند و در بخش بعدی بیشتر مورد تجزیه و تحلیل قرار می گیرند. هدف از بهینه سازی تعیین چگالی بهینه استقرار BS ها، λ_{BS} ، با توجه به مقادیر توان انتقال P_{tx} است. ثابت شده است که این مسئله بهینه سازی دارای یک راه حل منحصر به فرد است که با

ریشه منحصر به فرد یک معادله غیر خطی مطابقت دارد. این امکان محاسبه کارآمد چگالی BS های بهینه را برای هر مقدار معینی از توان ارسالی را نشان می دهد که امکان تولید ساده یک مجموعه آموزشی بزرگ حاوی جفت های بهینه $(P_{tx}, \lambda_{BS}^{(opt)})$ که $\lambda_{BS}^{(opt)} = \arg \max_{\lambda_{BS}} \{EE(\lambda_{BS})\}$ می باشد را فراهم می کند. چنین مجموعه آموزشی برای اولین مرحله آموزشی یک ANN که ورودی آن P_{tx} و خروجی آن $\lambda_{BS}^{(opt)}$ است استفاده می شود.

بهینه سازی داده محور. در موردی که نمی توانیم به هیچ مدل تحلیلی تکیه کنیم، مقادیر EE باید با جمع آوری نمونه های تجربی از شبکه سلولی تخمین زده شود، که از آن چگالی BS بهینه باید استنباط شود. به طور خاص، راندمان طیفی و توان مصرفی را می توان به ترتیب به صورت زیر تخمین زد:

$$PSE(\cdot) = \frac{1}{AreaNet} \sum_{Cell(1) \in Net} \sum_{N_{MT} \in Cell(1)} \frac{B_W}{N_{MT}} \log_2(1 + \gamma_D) \mathbf{1}(SIR \geq \gamma_D, \overline{SNR} \geq \gamma_A). \quad (9)$$

$$P_{grid}(\cdot) = \frac{1}{AreaNet} \left(\sum_{Cell(0) \in Net} P_{idle} + \sum_{Cell(1) \in Net} \left(P_{tx} + P_{circ} \sum_{N_{MT} \in Cell(1)} N_{MT} \right) \right). \quad (10)$$

دو فرمول قبلی را می توان به صورت زیر تفسیر کرد. با در نظر گرفتن کارایی طیفی برای اصلاح، هر پایانه سیار در شبکه سلولی بر اساس سیگنال دریافتی تعیین می کند که آیا در پوشش قرار دارد یا خیر. این کار با اندازه گیری میانگین نسبت سیگنال به نویز در طول فاز ارتباط سلولی و نسبت سیگنال به تداخل در طول انتقال داده (اگر فاز اول موفقیت آمیز بود) انجام می شود. این شرط مربوط به عبارت ۱ $\mathbf{1}(SIR \geq \gamma_D, \overline{SNR} \geq \gamma_A)$ که در آن تابع نشانگر است. هر پایانه تلفن همراه می تواند یک بیت اطلاعات را به یک کنترلر شبکه ارسال کند تا گزارش دهد که آیا تحت پوشش است یا خیر. بر اساس تعداد پایانه های تلفن همراه که در یک سلول معین (N_{MT}) تحت پوشش هستند، BS آن سلول به طور مساوی طیف موجود (B_W) را بین آنها تخصیص می دهد و داده ها را با نرخ ثابت $(B_W/N_{MT}) \log_2(1 + \gamma_D)$ ارسال می کند. علاوه بر این، با بهره برداری از اطلاعات تمام پایانه های سیار، می توان BS هایی را که حداقل به یک پایانه سیار (سلول ۱) خدمت می کنند را شناسایی کرد و تعداد پایانه های موبایلی را که در هر یک

از آنها وجود دارد برای هر شبکه محاسبه کرد. سپس بازده طیفی را می توان با جمع کردن نرخ تمام BS های فعال و با نرمال سازی آن با ناحیه شبکه تحت تحلیل تخمین زد. اگر متغیر بهینه سازی چگالی BS باشد، تمام مقادیر ممکن چگالی باید آزمایش شوند و مقدار متناظر با EE بهینه ثبت شود و برای آموزش ANN استفاده شود. بر اساس این توصیف ساده، ما به راحتی می توانیم درک کنیم که مقدار داده های تجربی لازم برای آموزش یک ANN که فقط به بهینه سازی مبتنی بر داده متوسل می شود، ناچیز نخواهد بود، در نتیجه باعث سربار قابل توجهی می شود.

نتایج عددی شکل های ۳-۳ و ۳-۴ چند مثال عددی را نشان می دهند که عملکرد رویکرد یادگیری انتقال توصیف شده را تحلیل می کنند. یک معماری ANN پیش خور با لایه های کاملاً متصل و توابع فعال سازی ReLU در نظر گرفته شده است. به طور خاص، پس از آزمایش بسیاری از پیکربندی های ANN مختلف، یک ANN با سه لایه پنهان مجهز به نورون های ۸، ۸ و ۲ انتخاب شد، زیرا مشخص شد که بهترین مصالحه عملکرد-پیچیدگی را به همراه دارد.

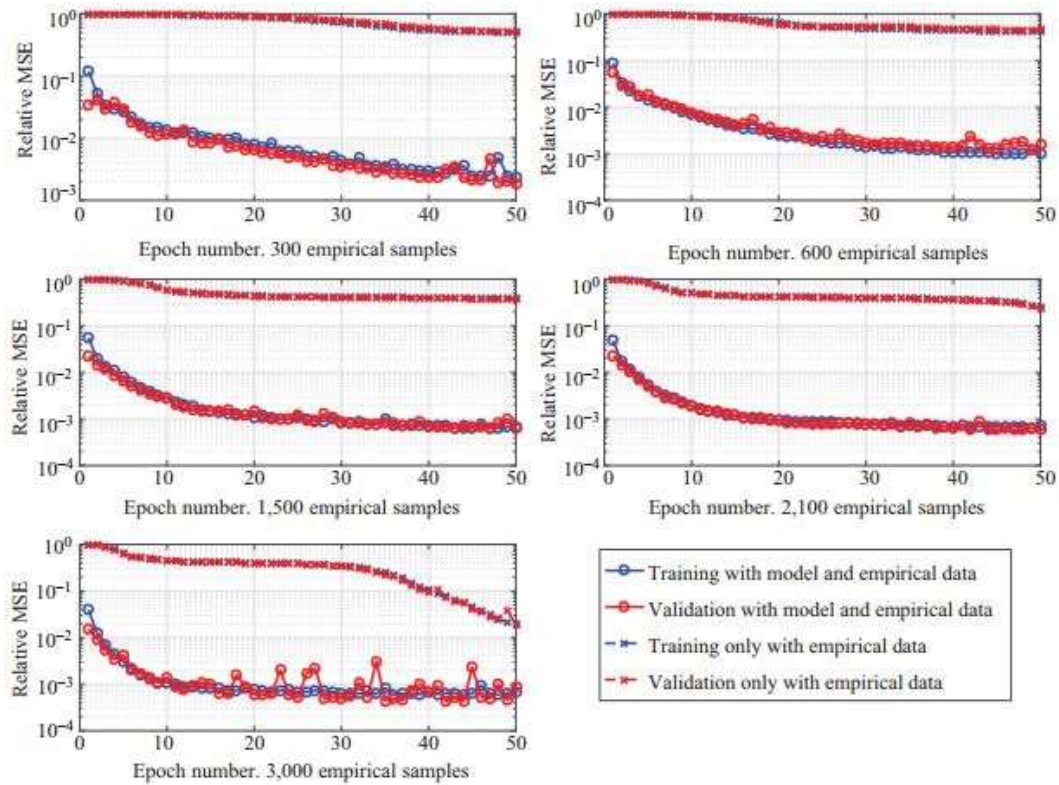
شکل ۳-۳ MSE مربوط به آموزش و اعتبار سنجی را در مقابل تعداد دوره های آموزشی برای رویکردهای زیر نشان می دهد:

- تکنیک یادگیری انتقال عمیق روشی که از نمونه های داده مبتنی بر مدل و داده های تجربی استفاده می کند.
- رویکرد پایه، که در آن فقط از نمونه داده های تجربی استفاده می شود.

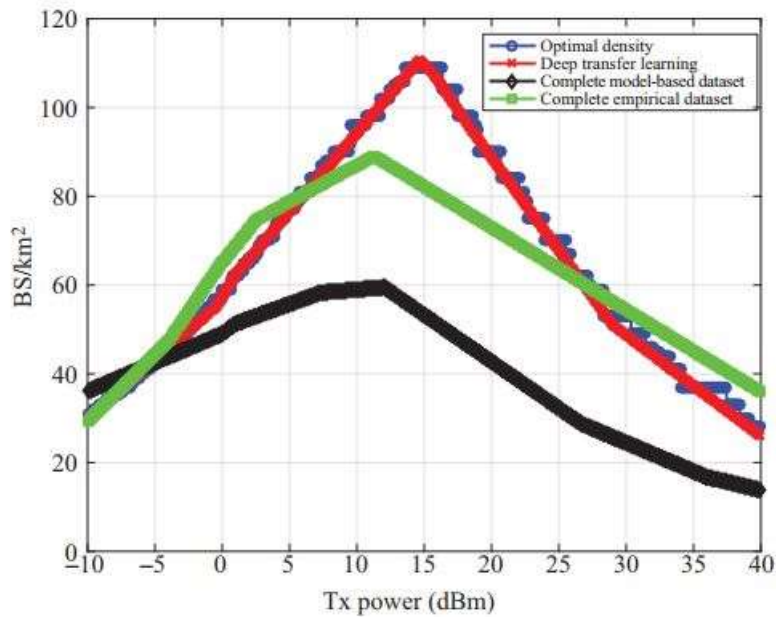
همانطور که برای رویکرد اول، اندازه مجموعه آموزشی همیشه برابر با 30000 نمونه است که از این میان x نمونه از توزیع BS واقعی (مدل شبکه مربع) پیروی می کنند، در حالی که بقیه $(30000 - x)$ نمونه از توزیع پواسون پیروی می کنند. در مورد رویکرد دوم، مجموعه آموزشی اتخاذ شده فقط شامل x نمونه تجربی است. بنابراین، این مقایسه از نظر تعداد نمونه های داده های تجربی به کار گرفته شده منصفانه است و هدف آن نشان دادن این است که افزودن مجموعه داده های کوچکی از داده های تجربی با مجموعه داده های بزرگ تری از داده های مبتنی بر مدل می تواند بهبود عملکرد قابل توجهی را ارائه دهد. برای هر دو رویکرد، مقادیر $x = 300.600.1500.2100.3000$ در نظر گرفته شده است، و برای هر مقدار x ، مشاهده می شود که روش یادگیری انتقال عمیق بسیار بهتر از رویکرد پایه عمل می کند.

یک ملاحظه مشابه در مرحله آزمایش نیز ظاهر می شود. شکل ۳,۴ چگالی BS ها را به عنوان تابعی از توان انتقال آنها با در نظر گرفتن مجموعه آزمایشی ۸۰۰۰ توان انتقال جدید نشان می دهد که به طور مستقل از مجموعه های آموزشی و اعتبار سنجی تولید شده اند. نتایج چهار طرح زیر مقایسه شده است:

- چگالی بهینه محاسبه شده از طریق جستجوی جامع،
- چگالی پیش بینی شده با استفاده از یادگیری انتقال عمیق، که در آن ۳۰۰۰ نمونه تجربی در مرحله دوم آموزش استفاده می شود،
- چگالی به دست آمده بدون یادگیری انتقال و انجام آموزش با استفاده از تنها ۳۰۰۰ نمونه تجربی
- چگالی به دست آمده بدون یادگیری انتقال و انجام آموزش تنها با استفاده از ۳۰۰۰۰ نمونه مبتنی بر مدل. مشاهده می شود که استفاده از تنها ۳۰۰۰ نمونه تجربی عملکرد بسیار بدتری را در مقایسه با روش یادگیری انتقال عمیق که همان ۳۰۰۰ نمونه داده تجربی را با داده های مبتنی بر مدل ادغام می کند، به همراه دارد. این نشان می دهد که چگونه انجام پیش آموزش مبتنی بر مدل قبل از استفاده از اندازه گیری های واقعی برای بهینه سازی سیستم می تواند بر کمبود نمونه های تجربی کافی غلبه کند. علاوه بر این، توجه به این نکته که استفاده از ۳۰۰۰۰ نمونه مبتنی بر مدل منجر به عملکرد رضایت بخشی نمی شود نیز مهم است. برای به دست آوردن عملکرد دقیق، استفاده از نمونه های داده مبتنی بر مدل و داده های تجربی ضروری است.



شکل ۳-۵ یادگیری و اعتبارسنجی MSE نسبی در مقابل دوره های آموزشی برای $x = 300. 600. 1500. 2100. 3000$ نمونه. برای هر مورد، عملکرد با و بدون نمونه های مبتنی بر PPP گزارش شده است. مشاهده می شود که چگونه استفاده از داده های مبتنی بر PPP به طور قابل توجهی عملکرد را بهبود می بخشد.



شکل ۴-۴ مقایسه بین بهینه سازی مبتنی بر مدل، مبتنی بر داده، و بهینه سازی مبتنی بر انتقال عمیق - استقرار بهینه

فصل چهارم

نتیجه گیری

این گزارش به شرح استفاده از هوش مصنوعی مبتنی بر یادگیری عمیق، یادگیری انتقال و شبکه‌های عصبی مصنوعی برای طراحی شبکه‌های بی سیم آینده کارآمد می‌پردازد. در پایان این فصل می‌توان دو نتیجه اصلی گرفت:

- با افزایش پیچیدگی شبکه‌های ارتباطی، توسعه شبکه‌های بی سیم هوشمند بیش از پیش ضروری می‌شود. نیازهای بیشتر و بیشتری در حال اجرا هستند، که نمی‌توان آنها را صرفاً با توسعه فناوری‌های انتقال سریعتر برآورده کرد، بلکه با بازنگری در کل معماری شبکه‌های بی سیم حاصل می‌شود. از این نظر، پارادایم محیط‌های رادیویی هوشمند ارائه شده است و نشان داده شد که چگونه یادگیری عمیق یک عامل اساسی برای بهینه‌سازی محیط‌های رادیویی هوشمند خواهد بود.
- پیچیدگی شبکه‌های بی سیم از توانایی ما برای استخراج مدل‌های ریاضی مناسب که خود را با پیچیدگی مقرون به صرفه بهینه می‌کنند، فراتر رفته است. در این زمینه، تکمیل دانش گذشته که توسط مدل‌های ریاضی (احتمالاً نادرست) ارائه شده، با کمک تکنیک‌های یادگیری عمیق مبتنی بر شبکه‌های عصبی مصنوعی، مصالحه‌های پیچیدگی-عملکرد عالی را ارائه می‌کند که نسبت به سایر چارچوب‌های بهینه‌سازی موجود کاملاً برتر است.

بنابراین، این گزارش نشان می‌دهد که در حالی که یادگیری عمیق یک ابزار ضروری برای طراحی شبکه‌های بی سیم آینده خواهد بود، اما نباید جایگزین پارادایم طراحی مبتنی بر مدل سنتی شود. برعکس، با استفاده مشترک از تکنیک‌های مبتنی بر داده و مبتنی بر مدل برای طراحی شبکه‌های بی سیم مزایای زیادی را می‌توان به دست آورد.

منابع و مراجع

- [1] Suraweera, H. A., Yang, J., Zappone, A., & Thompson, J. S. (2020). *Green communications for energy-efficient wireless systems and networks*. Institution of Engineering and Technology.



**Amirkabir University of Technology
(Tehran Polytechnic)**

Department Electrical Engineering

Term Paper of Modern Wireless Networks

**Green Communications for Energy-Efficient
Wireless Systems and Networks**

**By
Alireza Khayyatian**

**Supervisor
Dr. Abass Mohammadi**

December & 2021